Orientación de Proyecto: AquaLife

Bases de Datos
Licenciatura en Ciencia de Datos
Curso: 2026-2027

Este documento proporciona una orientación para el proyecto final de la asignatura. **La realización de este proyecto constituye un ejercicio por equipo de hasta tres estudiantes**.

Escenario

AquaLife es una plataforma digital de red social dedicada a conectar a entusiastas del acuarismo de todo el mundo. Su misión es crear una comunidad global donde los usuarios puedan compartir conocimientos sobre el cuidado de peces, invertebrados, plantas acuáticas y corales, descubrir nuevas especies, contribuir con sus experiencias mediante publicaciones y reacciones, y acceder a una tienda en línea para adquirir especies y productos relacionados (equipos, alimento, decoración). AquaLife busca democratizar el conocimiento sobre el mantenimiento de acuarios y fomentar prácticas responsables de acuarismo a través de la colaboración y el intercambio de experiencias entre usuarios.

Su equipo ha sido contratado como analistas de datos en la empresa AquaSolutions, creadores de la plataforma AquaLife. Debido a despidos masivos, todo el personal relacionado con el desarrollo de AquaLife ya no se encuentra disponible. Sin embargo, con vistas a mejorar la plataforma en el futuro, la empresa ha encargado obtener información acerca de su utilización por los usuarios e implementar una propuesta de mejora al diseño de la base de datos.

Como profesionales disponibles actualmente con conocimientos técnicos, su equipo desempeñará un papel crucial en la continuidad operativa de AquaLife. El trabajo consistirá en realizar ingeniería inversa sobre la base de datos existente para comprender su estructura y funcionamiento, extraer información valiosa mediante consultas analíticas, identificar patrones de comportamiento de usuarios y vendedores, y proponer mejoras al diseño de la base de datos que amplíen las funcionalidades de la plataforma. Además, será necesario desarrollar herramientas interactivas que permitan a los directivos de la empresa visualizar métricas clave y tomar decisiones informadas sobre el futuro de AquaLife. La capacidad para trabajar en equipo y el dominio de bases de datos será fundamental para el éxito de esta misión.

En equipo, y sin contar con ayuda de nadie en la empresa que conozca la base de datos de AquaLife, se deberá completar las tareas asignadas por la empresa.

Materiales provistos

Para el desarrollo del proyecto se le provee de los siguientes recursos disponibles:

- **Configuración Docker**: Archivo `docker-compose.yml` para desplegar un contenedor MySQL con la base de datos AquaLife.
- **Script de inicialización**: Archivo `init.sql` con las tablas y datos iniciales.
- **Documento de orientación**: El presente documento con los requerimientos y las tareas a desarrollar.
- **Instrucciones de uso**: Archivo `README.md` con instrucciones detalladas para la instalación, configuración y conexión a la base de datos desde diferentes entornos.

Tareas

1. Realizar un **fork** del repositorio del proyecto. Este repositorio será la base del trabajo y deberá contener todo el código y documentación desarrollada durante el proyecto. Asegurar mantener el repositorio actualizado con los avances.
2. A partir de la base de datos proporcionada, elaborar una propuesta de **modelo entidad-relación extendido (MERX)** que permita comprender conceptualmente el escenario planteado, respetando la concepción vista en clases. Se puede utilizar cualquier herramienta para su construcción; sin embargo, se recomienda emplear diagrams.net o Excalidraw.

3. Escribir código MySQL que responda a los siguientes ejercicios:

   a) **Termómetro de la comunidad**: Calcular la cantidad total de reacciones recibidas por cada publicación (bitácoras de mantenimiento, fotos de montajes, dudas sobre una especie, etc.), incluyendo la información de la publicación y de su autor.

   b) **Publicaciones mejor recibidas por la comunidad**: Identificar las publicaciones que presentan mayor cantidad de reacciones positivas que negativas, incluyendo sus detalles y la cantidad total de reacciones.

   c) **Perfil demográfico de la comunidad**: Analizar la distribución de edades de los usuarios de AquaLife por rangos de diez años (por ejemplo: $11-20$, $21-30$, ...), de forma que AquaSolutions pueda orientar mejor sus campañas. Devolver la cantidad de usuarios y el por ciento por rango de edad.

   d) **Tendencias de contribución según el tipo de agua**: Examinar cómo varían las bitácoras de mantenimiento (contribuciones) de acuerdo con el tipo de agua, identificando la especie y su categoría más popular en cada tipo de agua.

   e) **Vendedores mejor calificados**: Mostrar los cinco vendedores (tiendas y criadores) con mejor calificación promedio en la venta de especies y equipos, ordenados de forma descendente. De cada uno se debe incluir el total de productos vendidos, calificación promedio, nombre, correo electrónico y dirección particular.

   f) ***Trigger* de auditoría de precios**: Implementar un disparador que se active automáticamente cuando se modifique el precio de un producto. Este recurso es especialmente relevante en AquaLife, donde un cambio brusco en el precio de una especie puede indicar escasez, un error de publicación o manipulación de mercado. Este recurso debe:

      - Registrar en una tabla de auditoría (`Historial_Precios`) la información del cambio: producto afectado, precio anterior, precio nuevo, fecha, hora y usuario que realiza el cambio.
      - Calcular el porcentaje de cambio en el precio.
      - La tabla de auditoría debe ser creada con la estructura apropiada para almacenar estos datos.

   g) **Procedimiento almacenado para análisis de actividad de usuario**: Crear un procedimiento almacenado llamado `sp_analisis_usuario` que permita a AquaSolutions revisar de un vistazo el perfil de actividad de cualquier acuarista de la plataforma. Debe recibir como parámetros:

      - Identificador del usuario a analizar
      - Fecha inicial del período de análisis
      - Fecha final del período de análisis

      El procedimiento debe retornar un conjunto de resultados que incluya:

      - Total de publicaciones realizadas en el período
      - Total de reacciones dadas y recibidas
      - Total de comentarios realizados
      - Total de compras y monto gastado
      - Total de contribuciones (bitácoras de mantenimiento) realizadas
      - Especie más comprada y especie más contribuida

      Este procedimiento debe ser invocable desde la aplicación Streamlit, permitiendo al usuario introducir los parámetros de forma interactiva y visualizar los resultados en un formato amigable.

   h) **Análisis de influencers y su impacto en ventas**: Identificar a los 5 usuarios "*influencers*" de la comunidad (aquellos cuyas publicaciones sobre acuarismo generan más interacciones) y determinar si existe correlación entre su actividad y las ventas de las especies con las que interactúan, información que AquaSolutions puede usar para decidir con qué acuaristas colaborar. Para cada *influencer*, calcular:

      1) Su puntaje de interacciones ponderado (Me gusta=1, Me encanta=2, Me asombra=1,5, comentarios=2);
      2) Las especies con las que más ha interactuado (publicaciones, contribuciones, compras);
      3) El incremento porcentual en ventas de esas especies en las 2 semanas posteriores a sus publicaciones/contribuciones versus las 2 semanas anteriores;

4) La tasa de conversión: porcentaje de usuarios que compraron especies después de reaccionar a sus publicaciones.

i) **Detección de patrones de comportamiento anómalo en vendedores**: La venta de especies vivas hace que la reputación del vendedor sea crítica (un ejemplar mal manipulado o enfermo puede morir en tránsito), por lo que identificar vendedores con patrones de venta sospechosos es prioritario para AquaSolutions. Realizar el análisis de:

1) Vendedores que venden la misma especie o producto a precios significativamente diferentes ($> 30\,\%$ de variación) sin justificación temporal;
2) Vendedores con productos que tienen calificaciones extremadamente polarizadas (muchos 5 y muchos 1, pero pocos valores intermedios), lo que puede indicar envíos inconsistentes de ejemplares vivos;
3) Vendedores cuyos compradores nunca o raramente han comprado otros productos en la plataforma (posible manipulación);
4) Especies o productos vendidos por múltiples vendedores donde uno tiene un patrón de ventas muy diferente al resto. Para cada vendedor sospechoso, generar un "índice de sospecha" ponderado y listar las evidencias específicas detectadas.

4. En AquaLife, los comentarios sobre una publicación (una duda sobre por qué un pez no come, un pedido de ayuda por un brote de algas, una discusión sobre parámetros de agua) suelen encadenar varias respuestas de distintos usuarios. Implementar y comparar soluciones para permitir estas conversaciones en hilos utilizando diferentes modelos de datos:

   a) Modificar el diseño de la base de datos relacional para permitir conversaciones en los comentarios, es decir, permitir que los usuarios puedan responder comentarios de otros usuarios creando hilos (conversaciones internas).

   - Escribir el código para modificar la base de datos de acuerdo al diseño y generar conversaciones de prueba de longitud no menor que 20 subcomentarios (por ejemplo, un hilo de diagnóstico colaborativo sobre una enfermedad detectada en un acuario).
   - Escribir código para dado un comentario inicial obtener la conversación entera surgida a partir de dicho comentario.

   b) Modelar y resolver el mismo problema de conversaciones en comentarios utilizando otro modelo de datos visto en conferencias. Los identificadores de los comentarios deben ser los mismos en ambas bases de datos para facilitar la comparación.

   c) Comparar ambos diseños (relacional y no relacional) de acuerdo a las ventajas y desventajas que presentan para resolver este escenario.

5. Cada especie de AquaLife tiene necesidades de cuidado muy distintas entre sí (un pez de agua fría no comparte los mismos requisitos que un coral de arrecife), por lo que la plataforma necesita un sistema de documentación jerárquica para las especies. Cada especie debe tener asociado un **documento principal** (Ficha de Especie), que contiene información esencial sobre la especie y sus cuidados necesarios. Además, cada documento principal puede tener asociados múltiples **documentos secundarios** que complementan la información, tales como:

   - **Certificado Sanitario**: Información sobre el estado de salud y ausencia de parásitos o enfermedades del ejemplar.
   - **Guía de Alimentación Estacional**: Instrucciones específicas de alimentación según la temporada del año.
   - **Manual de Tratamiento de Enfermedades**: Procedimientos para prevenir y tratar enfermedades comunes (ich, hongos, parásitos, etc.).
   - **Historial de Crecimiento**: Registro del desarrollo esperado del ejemplar en diferentes etapas.
   - **Análisis de Agua**: Especificaciones detalladas sobre los parámetros de agua requeridos (pH, dureza, temperatura, amoníaco, nitritos, nitratos).

   Para esta tarea:

- Diseñar una solución de almacenamiento apropiada considerando que los documentos tienen estructuras variables y se organizan de forma jerárquica. Los identificadores de las especies deben coincidir con los de la base de datos provista. Justificar la elección del modelo de datos.
- Implementar la solución diseñada para almacenar documentos principales y secundarios asociados a especies.
- Insertar datos de prueba: al menos 5 fichas de especie, cada una con un mínimo de 3 documentos secundarios de tipos diferentes.
- Implementar una operación de consulta que, dado el identificador de una especie, retorne todos sus documentos (principal y secundarios) organizados jerárquicamente.

6. Desarrollar una aplicación web interactiva utilizando **Streamlit** que le sirva a los directivos de AquaSolutions y a la comunidad de AquaLife como panel de control sobre la plataforma. La aplicación debe incluir las siguientes funcionalidades:

   - **Selector de consultas**: Un desplegable que permita seleccionar cualquiera de las consultas SQL implementadas en las tareas anteriores (reacciones, vendedores mejor calificados, tendencias por tipo de agua, etc.), mostrando los resultados en una tabla interactiva.
   - **Análisis de usuario con procedimiento almacenado**: Interfaz interactiva que permita a un administrador introducir los parámetros del procedimiento almacenado `sp_analisis_usuario` (ID de usuario, fecha inicio, fecha fin) y visualizar el perfil de actividad de ese acuarista en formato amigable (tablas, gráficos, métricas) según convenga.
   - **Gestión de conversaciones**: Interfaz para que un usuario cree nuevos comentarios (por ejemplo, para responder una duda sobre el cuidado de una especie) y los asocie a hilos de conversación existentes, permitiendo la navegación jerárquica de las conversaciones.
   - **Explorador de documentos**: Funcionalidad para que un usuario seleccione una especie y visualice todos sus documentos asociados (Ficha de Especie y documentos secundarios: certificado sanitario, guía de alimentación, análisis de agua, etc.) de forma organizada y jerárquica, antes de decidir adquirirla o cómo cuidarla.
   - **Gestor de precios de productos**: Interfaz que permita a un administrador de AquaSolutions seleccionar un producto (especie o equipo), visualizar su precio actual y modificarlo. Esta funcionalidad debe:
     - Mostrar una lista de productos con sus precios actuales
     - Permitir al usuario seleccionar un producto y cambiar su precio
     - Después de actualizar el precio, consultar y mostrar el historial de cambios de precio registrado por el *trigger* de auditoría, demostrando que el *trigger* se activó correctamente
     - Visualizar la tabla de auditoría con los cambios históricos de precios para el producto seleccionado

   La aplicación debe ser completamente funcional, con manejo de errores robusto y una interfaz intuitiva que facilite la interacción con los datos de AquaLife.

Restricciones Técnicas

Para el desarrollo de la aplicación Streamlit y la interacción con la base de datos, se deben cumplir las siguientes restricciones técnicas:

- **No se admite el uso de ORM**: No se permite utilizar bibliotecas ORM (como SQLAlchemy, Django ORM, Peewee, etc.) para el trabajo con la base de datos. El objetivo es que los estudiantes trabajen directamente con SQL y comprendan las operaciones de base de datos a bajo nivel.
- **Uso obligatorio de bibliotecas SQL nativas**: Debe utilizarse bibliotecas de Python que permitan definir la sintaxis SQL directamente, como por ejemplo:
  - `mysql-connector-python`

- `pymysql`
- `psycopg2` (para PostgreSQL)
- `sqlite3` (módulo estándar de Python)

- **Consultas SQL explícitas**: Todas las operaciones de base de datos deben realizarse mediante consultas SQL escritas explícitamente en el código, sin abstracciones de alto nivel. Esto incluye operaciones de SELECT, INSERT, UPDATE, DELETE, y llamadas a procedimientos almacenados.

Entrega y Defensa

La entrega y discusión del proyecto se realizará en la **semana 11** del curso académico, o en otra fecha si así se decide y comunica oportunamente.

Formato de entrega

El equipo deberá preparar un **repositorio** (público o privado con acceso compartido al profesor) que contenga:

- **Imagen del MERX**: Documento en formato `.pdf` o imagen (`.png`, `.jpg`) que muestre el modelo entidad-relación extendido de la base de datos original.
- **Carpeta del proyecto Streamlit**: Carpeta contenedora con el código fuente completo de la aplicación web y todos los scripts SQL utilizados en el proyecto, organizados de manera clara y estructurada.
- **Informe técnico**: Documento en formato `.pdf` que contenga:
  - Comparación entre los diseños relacional y no relacional para la implementación de conversaciones en comentarios (Tarea 4.c), incluyendo análisis de ventajas, desventajas y conclusiones sobre cuál modelo resulta más apropiado para este escenario.
  - Justificación de la elección del modelo de datos utilizado para el sistema de documentación jerárquica de especies (Tarea 5), explicando por qué es la solución más apropiada considerando la estructura variable y jerárquica de los documentos.
  - Cualquier otra consideración técnica relevante sobre las decisiones de diseño tomadas durante el proyecto.
- **README**: Archivo `README.md` con instrucciones claras para la configuración y ejecución del proyecto, incluyendo la estructura del repositorio, requisitos previos, pasos de instalación, y descripción breve de las funcionalidades implementadas.
- **Archivo docker-compose.yml**: Fichero `docker-compose.yml` actualizado con todas las configuraciones necesarias para desplegar los contenedores de base de datos utilizados en el proyecto (MySQL y cualquier otra base de datos adicional requerida).

Nota importante: Asegurar que el repositorio incluya un archivo `.gitignore` apropiado que excluya credenciales, archivos temporales y dependencias que puedan ser reinstaladas.